Benchmark des modèles Ollama

Équipe G16 - Story RAG API (histoire de Léo et Éclair)

1. Contexte et méthode

Le projet répond à des questions d'enfants sur une histoire (**story.txt**) : les passages pertinents sont retrouvés dans ChromaDB (embeddings **nomic-embed-text**), puis un LLM Ollama rédige la réponse avec le prompt système de **api.py**. Seul le LLM change entre les tests ; la recherche, le prompt et la température (0,2) sont identiques.

10 questions : 8 dont la réponse est dans l'histoire (faits, liste, raisonnement) et 2 pièges dont la réponse n'y est pas (le bon comportement est de dire que l'histoire ne le précise pas). Un score automatique par mots-clés est calculé, puis les réponses ont été relues. Machine de test : Windows 11, 15 Go de RAM, **CPU seul (pas de GPU)**. Le mode « réflexion » des modèles a été désactivé (réponse directe).

2. Résultats

Modèle	Taille disque	Réponses justes	Temps moyen / réponse	Vitesse (tokens/s)
qwen3.5:4b	3,3 Go	100 %	20.3 s	7.7
llama3.2:3b	2,0 Go	95 %	24.4 s	9.0
gemma3:4b	3,4 Go	100 %	29.9 s	8.8

Score par question (1 = correct, 0,5 = partiel)

Question	Type	qwen3.5:4b	llama3.2:3b	gemma3:4b
Comment s'appelle le cheval de Léo ?	fait	1.0	1.0	1.0
De quelle couleur est le cheval de Léo ?	fait	1.0	1.0	1.0
Qu'y a-t-il dans le sac à dos de Léo ?	liste	1.0	1.0	1.0
Qui est le méchant de l'histoire ?	fait	1.0	1.0	1.0
Que fait la machine du Baron Grognon ?	fait	1.0	1.0	1.0
Combien d'écureuils attaquent la machine ?	fait	1.0	1.0	1.0
Comment Léo arrête-t-il la machine à vapeur ?	raisonnement	1.0	0.5	1.0
Que donne Léo au Baron à la fin ?	fait	1.0	1.0	1.0
Quel est le prénom de la mère de Léo ?	hors-sujet	1.0	1.0	1.0
Quel âge a Léo ?	hors-sujet	1.0	1.0	1.0

3. Analyse

qwen3.5:4b : 100 % de réponses justes, 20.3 s en moyenne.

llama3.2:3b : 95 % de réponses justes, 24.4 s en moyenne. Réponse partielle à « Comment Léo arrête-t-il la machine à vapeur ? » : Léo arrête la machine à vapeur en faisant bombarder l'entrée de l'engin avec des glands ronds !

gemma3:4b : 100 % de réponses justes, 29.9 s en moyenne.

4. Limites

Seulement 10 questions sur une histoire courte (11 morceaux) : les écarts de qualité sont faibles et ne sont pas statistiquement significatifs. Les temps dépendent du processeur (pas de GPU) et incluent la lecture des passages par le modèle. Le modèle par défaut du dépôt, qwen2.5:1.5b, n'a pas été testé ici.

5. Conclusion

Pour cette mission, **qwen3.5:4b** est le meilleur compromis dans nos tests : il obtient le meilleur score et reste parmi les plus rapides, et il refuse correctement de répondre quand l'histoire ne le précise pas. **gemma3:4b** est aussi fiable mais un peu plus lent. **llama3.2:3b** est le plus léger (2,0 Go) mais oublie des éléments dans les réponses de raisonnement. Tous restent lents sur CPU : un GPU ou un modèle plus petit améliorerait nettement le temps de réponse.